



Ciência de Dados e Jogos Digitais: Descobrendo Insights por Meio dos Dados



Semana Acadêmica TDS 2026

Análise da coleção de dados da plataforma **Steam** sobre preço, gênero, avaliações, tempo de jogo e muito mais.

Professor Dr. Marcos Roque da Rosa

Por que Ciência de Dados?

- Dados estão em todos os lugares:
 - Sistemas, redes sociais, sensores, governos, empresas
- Organizações tomam **decisões baseadas em dados**
- Ciência de Dados como **diferencial profissional** em TI
- Relação com desenvolvimento de sistemas, bancos de dados e **inteligência computacional**



O que é Ciência de Dados?

- Área **interdisciplinar** que envolve:

- Estatística
- Matemática
- Programação
- Análise de dados
- Conhecimento do domínio
- Inteligência Artificial
- Machine Learning


- Foco em:

- Extrair informações
- Identificar **padrões**
- Apoiar decisões




Onde a Ciência de Dados é aplicada?

- Exemplos práticos:
 - Negócios e marketing
 - Saúde
 - Educação
 - Energia e sustentabilidade
 - Sistemas inteligentes
 - Governo e políticas públicas
 - **Games!**



Dados não são respostas

- Ter muitos dados não significa ter informação.
- Imagine: 124 mil jogos
 - 42 campos por jogo
 - Milhões de valores
 - Mas... O que podemos descobrir?
- A Ciência de Dados transforma:
 - **Dados → Informação → Conhecimento → Insight → Decisão**




Metodologia de Ciência de Dados

- Fornece uma **estrutura orientadora** e não depende de tecnologias ou softwares específicos.
- **A Analogia da Culinária:**
 - Antes de cortar os ingredientes (dados), você precisa **planejar** a refeição e ter uma receita.
 - O processo envolve **identificar** ingredientes, **prepará-los**, **cozinhá-los** e, crucialmente, **provar** a comida para verificar se precisa de ajustes.



Foundational Methodology for Data Science


John Rollins, um experiente cientista de dados da IBM, propôs uma metodologia composta por **10 etapas** que compõem um processo iterativo (um **ciclo de feedback contínuo**).



John B. Rollins (2015)

Dataset Steam

- **Steam Games Dataset**, mantido pela Fronkon Games e disponibilizado no Hugging Face.
- **Unidade de análise:** cada linha representa um jogo, e não um usuário.
- O objetivo é **percorrer os campos** do dataset e usar código para **responder perguntas** sobre os dados, preparando o caminho para análises e visualizações mais avançadas.



Fonte: <https://huggingface.co/datasets/FronkonGames/steam-games-dataset>



Stage 1: Business Understanding

Entendimento do negócio

Antes de analisar dados precisamos entender:

- Qual é o **problema**?
- Qual é o **objetivo**?
- Quem precisa da **resposta**?
- Qual **decisão** será apoiada?
- Como saberemos se o projeto foi bem-sucedido?

Compreender os objetivos antes da mineração/análise reduz o risco de investigar dados que não respondem ao problema.

Pergunta: Qual problema estamos tentando resolver?



Exemplo Dataset Steam

Nosso problema:

- Temos milhares de jogos disponíveis na Steam.

Queremos descobrir:

- **Quais características estão associadas ao alcance e ao engajamento dos jogos?**

Queremos investigar:

- gênero;
- preço;
- idiomas;
- sistema operacional;
- avaliações;
- proprietários estimados;
- usuários simultâneos;
- tempo de jogo.

Objetivo: identificar padrões no mercado de jogos com base em dados.



Stage 2: Analytic Approach

Abordagem Analítica

Podemos utilizar:

- **Descritiva**
 - O que aconteceu?
- **Diagnóstica**
 - Por que aconteceu?
- **Preditiva**
 - O que pode acontecer?
- **Prescritiva**
 - O que deveríamos fazer?

Agora precisamos decidir:
Como os dados serão analisados?



Exemplo Dataset Steam

Análise exploratória de dados — EDA

Vamos procurar:

- **distribuições;**
- **padrões;**
- **diferenças;**
- **associações;**
- **outliers;**
- **relações** entre variáveis.

Exemplos

- Qual gênero possui mais jogos?
- Qual gênero possui maior alcance?
- Jogos gratuitos possuem mais proprietários?
- Existe associação entre idioma e alcance?
- Quanto tempo os jogadores permanecem jogando?



Stage 3: Data Requirements

Requisitos de Dados

É necessário identificar:

- variáveis;
- fontes;
- formato;
- granularidade;
- período;
- qualidade esperada.

De quais dados precisamos para responder às perguntas?

Não devemos coletar dados simplesmente porque eles existem.

Devemos coletar os dados necessários para responder à pergunta.



Exemplo Dataset Steam

Requisitos de Dados

Pergunta	Dados (campos do dataset)
Quantos jogos existem?	applID, name
Quanto custam?	price
Qual alcance?	estimated_owners
Popularidade?	peak_ccu
Quais gêneros?	genres
Quais idiomas?	supported_languages
Quais plataformas?	windows, mac, linux
Como são avaliados?	positive, negative
Quanto jogam?	average_playtime_*



Stage 4: Data Collection

Coleta de Dados

- Agora precisamos obter os dados.
- Possíveis fontes:
 - APIs;
 - bancos de dados;
 - arquivos **CSV**;
 - arquivos **Parquet**;
 - pesquisas;
 - sensores;
 - web scraping;
 - dados públicos.

A coleta precisa considerar a **qualidade, a integridade e a adequação à pergunta.**



Exemplo Dataset Steam

Coleta de Dados

- **Fonte:** FronkonGames — Steam Games Dataset
- Disponível no Hugging Face.
- **Formato utilizado:** Parquet
- **124 mil jogos**
- 183 MB
- **Estrutura: 1 linha = 1 jogo**

Parquet é um formato de estrutura colunar que organiza e armazena dados em colunas (em vez de linhas, como no CSV ou em bancos relacionais tradicionais), padrão no Big Data.

Outras bases de dados:

kaggle

<https://www.kaggle.com/>



<https://steamdb.info/>



Stage 5: Data Understanding

Entendimento dos Dados

- Agora começa a exploração.
- Precisamos descobrir:
 - Quantas linhas?
 - Quantas colunas?
 - Quais tipos?
 - Existem valores ausentes?
 - Existem duplicados?
 - Qual a distribuição dos valores?
 - Existem valores estranhos?

Pergunta: "O que realmente temos nas mãos?"

Entender a **estrutura**, as **relações**, os **padrões**, as **distribuições**, os valores **ausentes** e os **extremos** é fundamental antes da preparação.



Ferramentas para EDA - Exploratory Data Analysis

- Pandas — biblioteca para trabalhar com tabelas e estruturas de dados
- NumPy — Biblioteca fundamental para operações numéricas em Python
- Matplotlib — Biblioteca base para criação de gráfico
- Scikit-learn — Biblioteca de Machine Learning para Python.
- NLTK e spaCy — Bibliotecas para Natural Language Processing (NLP).



Exemplo Dataset Steam

```
import pandas as pd
# Leitura do arquivo para o DataFrame dados
dados = pd.read_parquet("train-00000-of-00001.parquet")
# Quantidade de linhas e colunas
print(f"Linhas: {dados.shape[0]}")
print(f"Colunas: {dados.shape[1]}")
# descobrir quais campos existem, seus tipos
dados.info()
# 10 primeiros registros
dados.head()
# valores ausentes
dados.isna().sum()
# Estatísticas de valores, média, desvio-padrão, mínimo e quartis.
dados.describe()
```

Descobrimos que:

- temos milhares de jogos;
- existem variáveis numéricas;
- existem variáveis booleanas;
- existem textos;
- existem listas;
- existem valores ausentes.



Stage 6: Data Preparation

Preparação dos Dados

- Os dados raramente estão prontos para análise.
- Podemos precisar:
 - corrigir tipos;
 - tratar valores ausentes;
 - remover duplicados;
 - transformar variáveis;
 - criar novas variáveis;
 - normalizar dados;
 - transformar estruturas.

A preparação é uma das **etapas mais importantes** e frequentemente mais trabalhosas de um projeto de Ciência de Dados



Stage 7: Modeling

Modelagem

- Agora chegamos à etapa que muitas pessoas associam imediatamente à Ciência de Dados.
- Podemos utilizar:
 - regressão;
 - classificação;
 - clustering;
 - árvores de decisão;
 - random forest;
 - redes neurais;
 - machine learning;
 - etc.

Nem todo projeto precisa de Machine Learning.

Uma análise exploratória pode gerar insights importantes sem construir um modelo preditivo.



Stage 8: Evaluation

Avaliação

- Precisamos verificar:
 - qualidade dos dados;
 - tamanho da amostra;
 - distribuição;
 - outliers;
 - limitações;
 - validade das métricas;
 - possíveis vieses;
 - se a análise realmente responde à pergunta.

Precisamos perguntar: **O resultado é confiável?**



Stage 9: Deployment

Implantação

- O conhecimento produzido precisa chegar a quem vai utilizá-lo.
- Pode ser:
 - relatório;
 - **dashboard**;
 - sistema;
 - API;
 - recomendação;
 - modelo integrado a uma aplicação;
 - apresentação.

A implantação não precisa necessariamente significar colocar um modelo de Machine Learning em produção; os resultados podem ser entregues em **relatórios e recomendações**.



Stage 10: Feedback

Feedback


- A análise terminou? **Não.**
- Os resultados geram novas perguntas.
- Por exemplo, descobrimos que jogos de determinado gênero têm maior alcance. **Por quê?**
- Isso pode levar a:
 - novos dados;
 - novas variáveis;
 - nova análise;
 - novo modelo.
- **É por isso que o processo é iterativo.**



CRISP-DM: outra metodologia para Ciência de Dados

CRISP-DM (Cross-Industry Standard Process for Data Mining)

1. **Business Understanding** — compreender o problema e os objetivos do negócio.
2. **Data Understanding** — coletar, explorar e conhecer os dados.
3. **Data Preparation** — limpar, transformar e preparar os dados.
4. **Modeling** — construir modelos analíticos ou de Machine Learning.
5. **Evaluation** — avaliar os resultados e verificar se respondem ao problema.
6. **Deployment** — colocar os resultados ou modelos em uso.



Demonstração prática: do conceito ao código

- Vamos acompanhar o estudo do **dataset de jogos da Steam**, aplicando na prática as etapas que acabamos de estudar.
 - Carregamento e conhecimento dos dados
 - Análise da qualidade dos dados
 - Preparação e transformação das variáveis
 - Análise exploratória (EDA)
 - Estatísticas e visualizações
 - Identificação de padrões e possíveis insights
 - Interpretação dos resultados



<https://colab.research.google.com/>

EDA – Dataset Steam

- Linhas: **124.146**
- Colunas: **41**
- Valores ausentes: **0**
- Nomes duplicados: **Sim** (diferentes gêneros, proprietários, preço, notas)
- Pico de ano de lançamento: **2025** (24.973 jogos)
- Jogos com maior número de **proprietários**: **Dota 2, PUBG: BATTLEGROUNDS, Counter-Strike 2** (estimado: 150.000.000)
- Jogos com maior número de usuários **simultâneos**: Counter-Strike 2 (101.3936), Dota 2 (623.941)
- Jogos **gratuitos**: 26.412 - Jogos **pagos**: 97.734
- **Download** de conteúdo: Fantasy Grounds VTT (3.703)



EDA – Dataset Steam

- **Idade:** Mínima 0 (122.869) e **18 ou mais** (Gaijin Charenji 1 : Kiss or Kill, My Fake Goblin Wife, Escape from the hospital, I Saw Black Clouds, PAYDAY 2, Paintings Thief, Paladin's Horn)
- **Palavras** mais frequentes na descrição: 'game', 249691), ('world', 81298), ('new', 80461), ('play', 65445), ('time', 62380), ('features', 55556)
- **Idioma:** English (110.592), Simplified Chinese (34.185), German(30.124), French (29.935), Japanese (29.661)
- **Audio:** English (45.170), Simplified Chinese (8.355), Japanese (7.380), Russian (6.765), German (6.121)
- **Avaliação** Positiva: Counter-Strike 2 (7.642.084), PUBG: BATTLEGROUNDS (1.520.457), Dota 2 (2.037.143)



EDA – Dataset Steam

- **Sistemas Operacionais:** Windows (124.102), Mac (21.486), Linux (15.888)
- **Média de Tempo de Jogo (horas):** Avem33 (57.159), iTownGamePlay UNIVERSE (28.571), Letters From a Rainy Day -Oceans and Lace (5.994)
- Principais **desenvolvedores:** EroticGamesClub (232), Choice of Games (179), Boogygames Studios (157)
- **Gêneros:** Indie (81.746), Casual (50.886), Action (46.743), Adventure (45.726), Simulation (24.504), Strategy (22.725), RPG (21.259)
- **Categorias:** Single-player (10.9454), Family Sharing (97.237), Steam Achievements (56.512)



Machine Learning – Preço e Alcance

- **Random Forest Regressor:** é um modelo que combina várias **árvores de decisão** para prever um valor **numérico**.
 - Usa as características de um jogo para prever seu **preço**.
 - As árvores fazem previsões diferentes e o modelo combina essas previsões para chegar ao resultado final.
- **Random Forest Classifier:** combina várias árvores de decisão para classificar dados.
 - Podemos classificar o **alcance** de um jogo?
 - Qual é a faixa de alcance provável deste jogo? **Baixo:** até 20 mil owners; **Médio:** de 20 mil a 500 mil; **Alto:** acima de 500 mil.



Referências

- IBM. **The Data Science Lifecycle**. <https://public.dhe.ibm.com/software/data/sw-library/analytics/data-science-lifecycle/>
- Chapman, P. et al. **CRISP-DM 1.0: Step-by-step Data Mining Guide**. SPSS, 2000.
- FronkonGames. **Steam Games Dataset**. Hugging Face Datasets. DOI: 10.57967/hf/0511.
- **Pandas** — análise e manipulação de dados. <https://pandas.pydata.org/>
- **NumPy** — computação científica e operações numéricas. <https://numpy.org/>
- **Matplotlib** — visualização de dados. <https://matplotlib.org/>
- **Seaborn** — visualização estatística baseada no Matplotlib. <https://seaborn.pydata.org/>
- **Scikit-learn** — Machine Learning e análise preditiva. <https://scikit-learn.org/>
- **NLTK** — processamento de linguagem natural. <https://www.nltk.org/>
- **spaCy** — processamento de linguagem natural. <https://spacy.io/>

